SPEAKER GUIDE · CHƯƠNG 1–4

HƯỚNG DẪN THUYẾT TRÌNH

Hệ thống phân tích dữ liệu lớn theo thời gian thực
phát hiện tấn công mạng trong môi trường IoT

Trọng tâm: Chương 2 · Dữ liệu | Chương 3 · Kiến trúc Big Data | Chương 4 · Thực nghiệm

Tài liệu này hướng dẫn cách nói; không thay thế slide trình chiếu.

CÁCH SỬ DỤNG

Khung thuyết trình đề xuất

THỜI LƯỢNG GỢI Ý: 18–22 phút cho Chương 1–4

NGUYÊN TẮC

Không đọc nguyên văn chữ trên slide. Mỗi slide chỉ cần làm rõ một thông điệp: vấn đề dữ liệu cách xây hệ thống bằng chứng thực nghiệm. Chỉ số nào xuất hiện thì luôn nói ý nghĩa của nó đối với bài toán phát hiện tấn công.

Mở đầu + Chương 1	2–3 phút	Tạo nhu cầu cho một pipeline vận hành liên tục.
Chương 2 · Dữ liệu	5–6 phút	Chứng minh dữ liệu đủ lớn, hiểu rõ schema và tiền xử lý có kiểm soát.
Chương 3 · Hệ thống	7–8 phút	Làm rõ vai trò Spark, MLlib, Kafka, Structured Streaming, Streamlit và SQLite.
Chương 4 · Thực nghiệm	5–6 phút	Giải thích trade-off mô hình bằng số liệu và kết quả end-to-end.

CÁCH DIỄN ĐẠT

• Nói theo quan hệ nguyên nhân–kết quả, không liệt kê công nghệ.
• Dùng từ “nhóm” và “hệ thống”, tránh khẳng định quá mức như “chính xác tuyệt đối”.
• Khi gặp số lớn, đọc chậm và nêu ý nghĩa sau con số.

BA CÂU XƯƠNG SỐNG

• Dữ liệu lớn cần xử lý phân tán.
• Dòng sự kiện cần được suy luận liên tục, không chờ xử lý theo lô.
• Mô hình được chọn theo trade-off vận hành, không chỉ theo Accuracy.

MỞ ĐẦU

Slide 1–4 · Chào hội đồng và dẫn vào đề tài

SLIDE 1–4 · THỜI LƯỢNG GỢI Ý: 45–60 giây



Báo cáo Big Data

Đề tài: Xây dựng hệ thống phân tích dữ liệu lớn thời gian thực phát hiện xâm nhập mạng IoT

CÁCH NÓI

"Kính thưa thầy/cô và các bạn. Nhóm em trình bày đề tài xây dựng hệ thống phân tích dữ liệu lớn theo thời gian thực để phát hiện tấn công mạng trong môi trường IoT. Bài trình bày đi từ bài toán, bộ dữ liệu, kiến trúc xử lý đến kết quả thực nghiệm."

SLIDE THÀNH VIÊN VÀ MỤC LỤC

- Giới thiệu tên các thành viên rất ngắn; nếu có phân công thì chỉ nêu một câu.
- Ở mục lục, báo trước trọng tâm: dữ liệu, kiến trúc Big Data và kết quả đo được.
- Slide tiêu đề Chương 1 chỉ là nhịp chuyển: "Trước hết, nhóm xin trình bày lý do hình thành đề tài."

TRÁNH

Không dành hơn một phút để đọc tên đề tài, thành viên và toàn bộ mục lục. Người nghe cần biết câu hỏi nghiên cứu, không cần nghe lại mọi chữ trên màn hình.

CHƯƠNG 1 · TỔNG QUAN

Đặt vấn đề

SLIDE 5 · THỜI LƯỢNG GỢI Ý: 35–45 giây

MỤC TIÊU CỦA SLIDE

Giải thích vì sao môi trường IoT cần phát hiện sự kiện mạng ngay khi chúng xuất hiện.



LỜI NÓI GỢI Ý

"Các thiết bị IoT phát sinh dữ liệu mạng liên tục và có hành vi rất đa dạng. Nếu dữ liệu chỉ được gom lại rồi phân tích sau, cảnh báo sẽ đến muộn và làm giảm khả năng phản ứng. Vì vậy, bài toán của nhóm không chỉ là huấn luyện một mô hình phân loại, mà là xây dựng một luồng có thể tiếp nhận, phân tích và giám sát liên tục trong suốt phiên hoạt động."

ĐIỂM CẦN NHẤN

- Ba ý theo đúng thứ tự: liên tục, đa dạng, cần phản ứng sớm.
- Từ khóa của đề tài là "vận hành liên tục", không chỉ "độ chính xác mô hình".

CÂU CHUYỂN

"Vậy các cách tiếp cận phổ biến hiện nay giải quyết được đến đâu?"

LƯU Ý / KHÔNG NÊN NÓI

Không khẳng định mọi hệ thống hiện có đều chậm. Hãy nói đây là hạn chế thường gặp khi xử lý offline hoặc thiếu pipeline xuyên suốt.

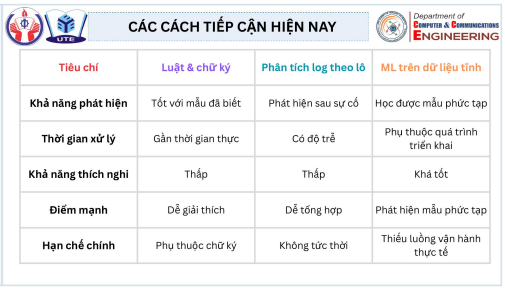
CHƯƠNG 1 · TỔNG QUAN

Các cách tiếp cận hiện nay

SLIDE 6 · THỜI LƯỢNG GỢI Ý: 45–60 giây

MỤC TIÊU CỦA SLIDE

Đặt giải pháp của nhóm trong bối cảnh luật/chữ ký, phân tích theo lô và ML trên dữ liệu tĩnh.



Tiêu chí	Luật & chữ ký	Phân tích log theo lô	ML trên dữ liệu tĩnh
Khả năng phát hiện	Tốt với mẫu đã biết	Phát hiện sau sự cố	Học được mẫu phức tạp
Thời gian xử lý	Gần thời gian thực	Có độ trễ	Phụ thuộc quá trình triển khai
Khả năng thích nghi	Thấp	Thấp	Khá tốt
Điểm mạnh	Dễ giải thích	Dễ tổng hợp	Phát hiện mẫu phức tạp
Hạn chế chính	Phụ thuộc chữ ký	Không tức thời	Thiếu luồng vận hành thực tế

LỜI NÓI GỢI Ý

"Luật và chữ ký dễ giải thích và xử lý nhanh với mẫu đã biết, nhưng khả năng thích nghi thấp. Phân tích log theo lô thuận tiện cho tổng hợp, nhưng chỉ cho kết quả sau khi đã gom dữ liệu. Machine Learning học được mẫu phức tạp hơn, tuy nhiên nếu chỉ dừng ở huấn luyện trên dữ liệu tĩnh thì vẫn thiếu phần vận hành thời gian thực. Do đó, nhóm kế thừa ưu điểm của ML và bổ sung pipeline dữ liệu liên tục."

ĐIỂM CẦN NHẤN

• So sánh theo tiêu chí, không phủ định hoàn toàn phương pháp cũ.
• Điểm thiếu nằm ở luồng vận hành, không phải ML tự thân.

CÂU CHUYỂN

"Khoảng trống cần giải quyết nằm giữa nguồn sự kiện liên tục và kết quả cảnh báo có thể theo dõi ngay."

NẾU THẦY HỎI

Nếu hỏi vì sao không dùng luật: luật vẫn hữu ích cho mẫu rõ ràng, nhưng đề tài cần nhận dạng mẫu đa chiều và minh họa một pipeline Big Data hoàn chỉnh.

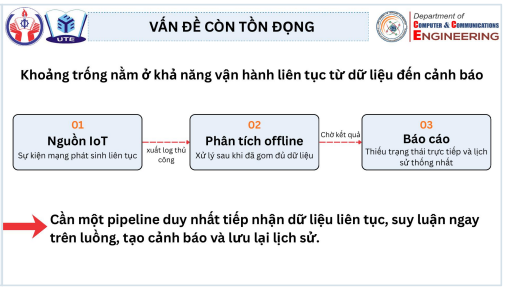
CHƯƠNG 1 · TỔNG QUAN

Vấn đề còn tồn đọng

SLIDE 7 · THỜI LƯỢNG GỢI Ý: 35–45 giây

MỤC TIÊU CỦA SLIDE

Chỉ ra đứt gãy của quy trình offline: xuất log thủ công, chờ xử lý và thiếu lịch sử thống nhất.



LỜI NÓI GỢI Ý

"Trong quy trình offline, nguồn IoT vẫn phát sinh sự kiện liên tục nhưng dữ liệu phải được xuất và gom trước khi phân tích. Kết quả vì thế có độ trễ, còn báo cáo thường tách rời trạng thái trực tiếp và lịch sử. Khoảng trống mà nhóm tập trung là một pipeline thống nhất: nhận sự kiện, suy luận ngay trên luồng, tạo cảnh báo, hiển thị và lưu lịch sử."

ĐIỂM CẦN NHẤN

- Nói rõ ba điểm đứt gãy trên mũi tên của slide.
- Từ "một pipeline duy nhất" nghĩa là luồng xuyên suốt, không có nghĩa chỉ một tiến trình phần mềm.

CÂU CHUYỂN

"Từ yêu cầu đó, nhóm đề xuất kiến trúc gồm bốn khối chính."

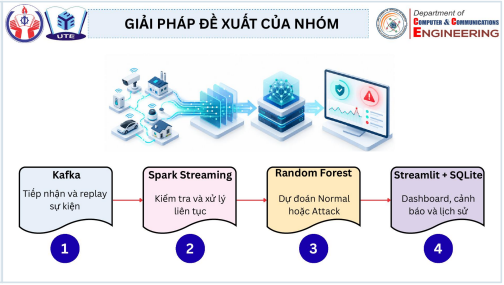
CHƯƠNG 1 · TỔNG QUAN

Giải pháp đề xuất của nhóm

SLIDE 8 · THỜI LƯỢNG GỢI Ý: 45–60 giây

MỤC TIÊU CỦA SLIDE

Giới thiệu rất ngắn bốn khối; chi tiết sẽ được giải thích ở Chương 3.



LỜI NÓI GỢI Ý

"Kafka tiếp nhận và đệm dòng sự kiện; Spark Structured Streaming kiểm tra và xử lý liên tục; mô hình Random Forest dự đoán Normal hoặc Attack; cuối cùng Streamlit hiển thị còn SQLite lưu lịch sử. Điểm quan trọng là các khối được nối thành một luồng từ dữ liệu đến cảnh báo, thay vì chỉ có một mô hình chạy độc lập."

ĐIỂM CẦN NHẤN

• Mỗi công nghệ chỉ nói một vai trò.
• Kafka không dự đoán; Spark Streaming không thay mô hình; SQLite không cấp dữ liệu live cho dashboard.

CÂU CHUYỂN

"Để xây dựng và kiểm chứng hệ thống này, trước hết nhóm cần một bộ dữ liệu IoT đủ lớn và có nhãn."

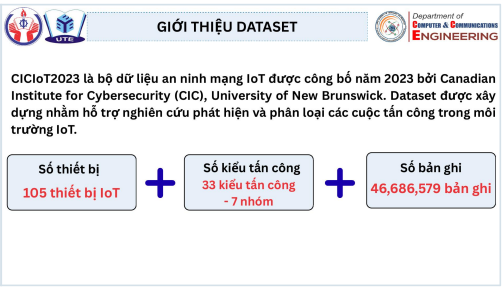
CHƯƠNG 2 · BỘ DỮ LIỆU

Giới thiệu CICIoT2023

SLIDE 9–10 · THỜI LƯỢNG GỢI Ý: 45–60 giây

MỤC TIÊU CỦA SLIDE

Giới thiệu nguồn, quy mô và độ đa dạng của bộ dữ liệu; không sa vào lịch sử bộ dữ liệu.



LỜI NÓI GỢI Ý

"Nhóm sử dụng CICIoT2023 do Canadian Institute for Cybersecurity thuộc University of New Brunswick công bố năm 2023. Bộ dữ liệu được xây dựng từ 105 thiết bị IoT, gồm 33 loại tấn công thuộc 7 nhóm và tổng cộng 46.686.579 bản ghi trong công bố. Đây là nguồn phù hợp vì vừa có quy mô lớn, vừa có nhiều kiểu hành vi mạng và có nhãn để huấn luyện có giám sát."

ĐIỂM CẦN NHẤN

- Đọc chậm bốn con số: 2023, 105 thiết bị, 33 kiểu tấn công/7 nhóm, 46,7 triệu bản ghi.
- Phân biệt quy mô công bố của dataset với 45.019.243 dòng CSV thực tế nhóm xử lý.

CÂU CHUYỂN

"Tuy nhiên, bộ dữ liệu có mức mất cân bằng lớp rất lớn."

NẾU THẦY HỎI

Nếu hỏi vì sao số công bố và số nhóm xử lý khác nhau: slide 10 mô tả toàn bộ dataset theo nguồn; pipeline của nhóm đọc 63 tệp CSV hiện có với 45.019.243 dòng.

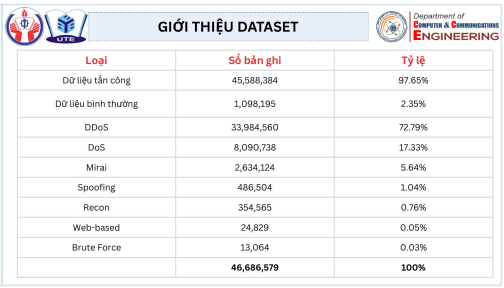
CHƯƠNG 2 · BỘ DỮ LIỆU

Phân bố nhãn và mất cân bằng lớp

SLIDE 11 · THỜI LƯỢNG GỢI Ý: 50–65 giây

MỤC TIÊU CỦA SLIDE

Cho thấy Attack áp đảo Normal và DDoS chiếm phần lớn, từ đó dẫn sang cách đánh giá mô hình.



GIỚI THIỆU DATASET

Loại	Số bản ghi	Tỷ lệ
Dữ liệu tấn công	45,588,384	97.65%
Dữ liệu bình thường	1,098,195	2.35%
DDoS	33,984,560	72.79%
DoS	8,090,738	17.33%
Mirai	2,634,124	5.64%
Spoofing	486,504	1.04%
Recon	354,565	0.76%
Web-based	24,829	0.05%
Brute Force	13,064	0.03%
	46,686,579	**100%**

LỜI NÓI GỢI Ý

"Trong phân bố gốc, Attack chiếm 97,65%, còn Normal chỉ 2,35%. Riêng DDoS đã chiếm 72,79% toàn bộ dữ liệu; tiếp theo là DoS và Mirai. Vì vậy Accuracy có thể rất cao chỉ do lớp Attack áp đảo. Ở phần thực nghiệm, nhóm phải đọc thêm Recall của Attack, Specificity của Normal, Balanced Accuracy và ma trận nhầm lẫn."

ĐIỂM CẦN NHẤN

- Nêu hệ quả của mất cân bằng, không đọc hết từng cột nhỏ.
- Normal là lớp thiểu số trong bộ dữ liệu này, khác trực giác của nhiều bài toán IDS.

CÂU CHUYỂN

"Tiếp theo, nhóm mổ xẻ cấu trúc 40 cột ban đầu và xác định tập đặc trưng phục vụ mô hình."

LƯU Ý / KHÔNG NÊN NÓI

Không gọi biểu đồ này là phân bố sau tiền xử lý; đây là phân bố gốc của bộ CICIoT2023.

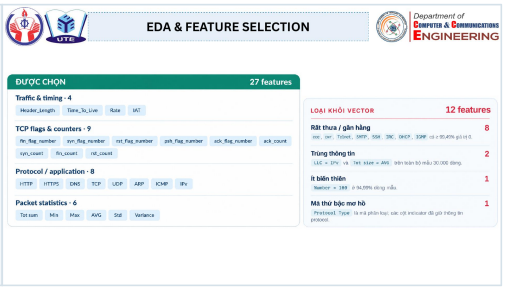
CHƯƠNG 2 · BỘ DỮ LIỆU

Từ 40 cột ban đầu đến 27 đặc trưng

SLIDE 12–13 · THỜI LƯỢNG GỢI Ý: 75–90 giây

MỤC TIÊU CỦA SLIDE

Giải thích 40 cột gồm 39 feature + Label; sau EDA giữ 27 feature và Label.



LỜI NÓI GỢI Ý

"Mỗi tệp ban đầu có 40 cột: 39 thuộc tính đầu vào và một cột Label. Nhóm kiểm tra schema của toàn bộ dữ liệu để bảo đảm 63 tệp có cùng cấu trúc, sau đó EDA trên các đặc trưng. Kết quả giữ 27 feature thuộc bốn nhóm: thời gian và lưu lượng; cờ và bộ đếm TCP; giao thức/ứng dụng; thống kê kích thước gói. Mười hai feature không phải nhãn bị loại vì gần như luôn bằng 0, trùng thông tin, biến thiên rất thấp hoặc là mã thứ tự khó diễn giải."

ĐIỂM CẦN NHẤN

- Công thức cần nhớ: 40 cột = 39 feature + 1 Label; đầu vào mô hình = 27 feature.
- Chọn feature sau khi khảo sát schema/EDA, nhưng trong pipeline chính thức chỉ ép kiểu và lọc lỗi trên 27 feature đã chọn.
- Không nói feature importance được dùng để chọn 27 cột; biểu đồ importance xuất hiện sau khi huấn luyện.

CÂU CHUYỂN

"Sau khi cố định hợp đồng 27 đặc trưng, nhóm áp dụng pipeline tiền xử lý thống nhất."

NẾU THẦY HỎI

Nếu hỏi vì sao bỏ Protocol Type: thông tin giao thức đã được giữ qua các cột chỉ báo TCP, UDP, ICMP, HTTP, HTTPS... nên mã thứ tự này dễ gây hiểu sai quan hệ số học.

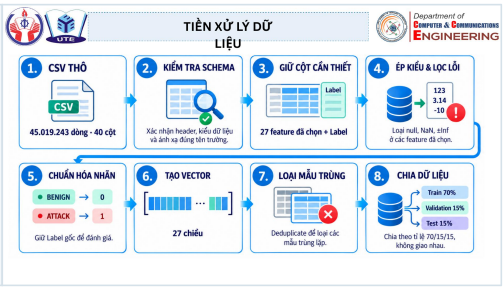
CHƯƠNG 2 · BỘ DỮ LIỆU

Pipeline tiền xử lý dữ liệu

SLIDE 14 · THỜI LƯỢNG GỢI Ý: 75–90 giây

MỤC TIÊU CỦA SLIDE

Trình bày đúng thứ tự nghiệp vụ: kiểm schema toàn tập giữ 27 feature + Label làm sạch trên tập đã chọn.



LỜI NÓI GỢI Ý

"Pipeline bắt đầu từ 63 tệp CSV với 45.019.243 dòng và 40 cột. Nhóm kiểm tra header, tên và kiểu mong đợi trên toàn bộ nguồn. Sau đó chỉ giữ 27 feature đã chọn cùng Label; các cột này được ép kiểu số và loại dòng chứa null, NaN hoặc vô cực. Nhãn gốc được chuẩn hóa thành BENIGN bằng 0 và ATTACK bằng 1, nhưng Label gốc vẫn được giữ để đánh giá. Tiếp theo tạo vector 27 chiều, loại mẫu học trùng và cuối cùng chia Train–Validation–Test theo tỷ lệ 70–15–15 với seed 42."

ĐIỂM CẦN NHẤN

• Kiểm schema áp dụng trên toàn bộ 40 cột để xác nhận nguồn đúng; làm sạch số tập trung trên 27 feature được dùng.
• Loại trùng trước khi chia để cùng một mẫu học không rơi vào nhiều tập và gây leakage.
• Validation dùng chọn mô hình; Test chỉ đánh giá một lần sau khi quyết định đã đóng băng.

CÂU CHUYỂN

"Sau pipeline này, số dòng giảm mạnh chủ yếu do dữ liệu trùng, không phải do dữ liệu lỗi."

NẾU THẦY HỎI

Nếu hỏi tại sao không chia trước rồi mới loại trùng: làm vậy có thể để bản sao của cùng một vector xuất hiện ở Train và Test, khiến điểm số lạc quan giả.

CHƯƠNG 2 · BỘ DỮ LIỆU

Kết quả sau tiền xử lý

SLIDE 15 · THỜI LƯỢNG GỢI Ý: 60–75 giây

MỤC TIÊU CỦA SLIDE

Đọc đúng sự suy giảm số dòng và chứng minh đầu ra đạt điều kiện huấn luyện.



LỜI NÓI GỢI Ý

"Từ 45.019.243 dòng thô, chỉ 1.000 dòng bị loại vì giá trị không hợp lệ, còn 45.018.243 dòng ML-ready. Sau khi loại 24.655.458 mẫu học trùng, còn 20.362.785 mẫu duy nhất. Dữ liệu được chia thành 14.253.082 dòng Train, 3.053.542 Validation và 3.056.161 Test. Các kiểm tra cuối xác nhận không còn null, NaN, vô cực hay mẫu trùng xuyên tập; vector luôn có 27 chiều và nhãn chỉ còn hai lớp."

ĐIỂM CẦN NHẤN

- Nguyên nhân giảm lớn là dedup, không phải lọc lỗi.
- Đọc số theo nhóm triệu, dừng nhẹ sau mỗi mốc.
- "Không trùng xuyên tập" là bằng chứng chống leakage.

CÂU CHUYỂN

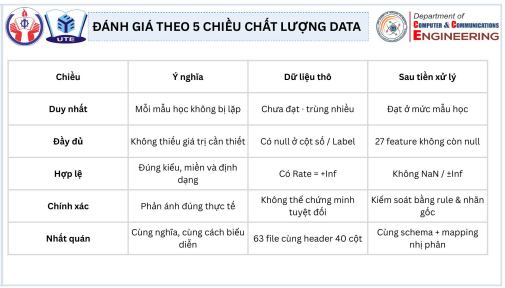
"Các kiểm tra này có thể được hệ thống hóa thành năm khía cạnh chất lượng dữ liệu."

Năm khía cạnh chất lượng dữ liệu

SLIDE 16 · THỜI LƯỢNG GỢI Ý: 55–70 giây

MỤC TIÊU CỦA SLIDE

Phân biệt chất lượng dữ liệu với 5V của Big Data; chỉ nêu minh chứng đo được.



Chiều	Ý nghĩa	Dữ liệu thô	Sau tiền xử lý
Duy nhất	Mỗi mẫu học không bị lặp	Chưa đạt · trùng nhiều	Đạt ở mức mẫu học
Đầy đủ	Không thiếu giá trị cần thiết	Có null ở cột số / Label	27 feature không còn null
Hợp lệ	Đúng kiểu, miền và định dạng	Có Rate = +Inf	Không NaN / ±Inf
Chính xác	Phản ánh đúng thực tế	Không thể chứng minh tuyệt đối	Kiểm soát bằng rule & nhãn gốc
Nhất quán	Cùng nghĩa, cùng cách biểu diễn	63 file cùng header 40 cột	Cùng schema + mapping nhị phân

LỜI NÓI GỢI Ý

"Nhóm đánh giá dữ liệu theo năm khía cạnh chất lượng. Duy nhất được cải thiện bằng loại mẫu học trùng; đầy đủ bằng việc không còn null ở 27 feature; hợp lệ bằng việc loại NaN và vô cực; nhất quán bằng schema chung và ánh xạ nhãn thống nhất. Riêng tính chính xác ngữ nghĩa không thể chứng minh tuyệt đối chỉ từ dữ liệu, nên nhóm kiểm soát bằng quy tắc và giữ Label gốc để đối chiếu."

ĐIỂM CẦN NHẤN

• Thừa nhận giới hạn của Accuracy dữ liệu là cách nói học thuật.
• Năm khía cạnh này là uniqueness/completeness/validity/accuracy/consistency, không phải Volume/Velocity/Variety/Veracity/Value.

CÂU CHUYỂN

"Từ dữ liệu đã chuẩn hóa, nhóm xây dựng kiến trúc huấn luyện offline và suy luận realtime dùng chung hợp đồng 27 đặc trưng."

CHƯƠNG 3 · KIẾN TRÚC VÀ XỬ LÝ BIG DATA

Vai trò của từng công nghệ

SLIDE 17–18 · THỜI LƯỢNG GỢI Ý: 60–75 giây

MỤC TIÊU CỦA SLIDE

Chứng minh việc chọn công nghệ theo chức năng trong pipeline, không phải liệt kê logo.



LỜI NÓI GỢI Ý

"Spark xử lý phân tán 63 tệp CSV, kiểm tra và tạo vector 27 chiều. MLlib huấn luyện, đánh giá, lưu và nạp lại Random Forest. Kafka đóng vai trò bộ đệm dòng sự kiện và tách producer khỏi consumer. Structured Streaming đọc Kafka, kiểm tra schema, nạp model đã lưu và tính metric theo event time. Streamlit đọc snapshot JSON để hiển thị bốn trang; SQLite lưu bền predictions, metrics và alerts."

ĐIỂM CẦN NHẤN

- Mỗi thành phần có một trách nhiệm chính.
- JSON phục vụ trạng thái live; SQLite phục vụ lịch sử bền vững.
- Mô hình được huấn luyện bằng MLlib và cũng được nạp trong Spark Streaming.

CÂU CHUYỂN

"Các thành phần này được tổ chức thành hai nhánh: offline để tạo model và realtime để vận hành model."

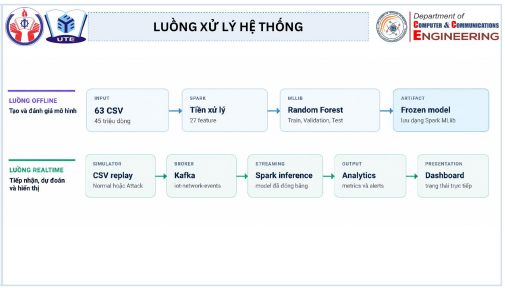
CHƯƠNG 3 · KIẾN TRÚC VÀ XỬ LÝ BIG DATA

Kiến trúc tổng thể: offline và realtime

SLIDE 19 · THỜI LƯỢNG GỢI Ý: 75–90 giây

MỤC TIÊU CỦA SLIDE

Giải thích ranh giới huấn luyện và suy luận, cùng hợp đồng 27 feature xuyên suốt.



LỜI NÓI GỢI Ý

"Nhánh offline đọc khoảng 45 triệu dòng từ 63 CSV, tiền xử lý bằng Spark và huấn luyện Random Forest bằng MLlib. Sau khi so sánh trên Validation, quyết định được đóng băng và model được lưu. Nhánh realtime không huấn luyện lại: producer replay bản ghi thành sự kiện, Kafka đệm dòng, Spark Streaming tạo đúng vector 27 chiều rồi gọi model đã lưu. Kết quả dự đoán được chuyển sang analytics, cảnh báo, dashboard và lịch sử."

ĐIỂM CẦN NHẤN

- Train once, load many: realtime chỉ suy luận.
- Cùng thứ tự/tên 27 feature ở cả offline và realtime để tránh training–serving skew.
- Đây là kiến trúc Big Data vì có xử lý phân tán, streaming, event time và lưu lịch sử.

CÂU CHUYỂN

"Trước tiên, nhóm trình bày chi tiết cách Random Forest được huấn luyện trên MLlib."

NẾU THẦY HỎI

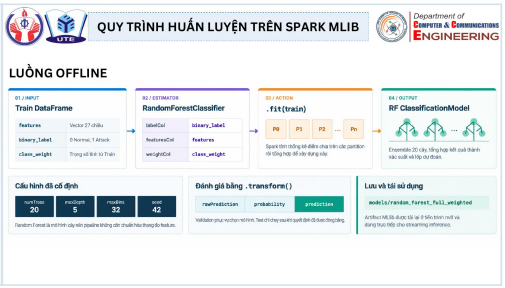
Nếu hỏi có tự học online không: không. MVP dùng model đóng băng; tái huấn luyện là một quy trình offline riêng.

Quy trình huấn luyện Random Forest bằng MLlib

SLIDE 20 · THỜI LƯỢNG GỢI Ý: 80–95 giây

MỤC TIÊU CỦA SLIDE

Làm rõ dữ liệu phân tán, class weight, siêu tham số và cách dùng Validation/Test.



LỜI NÓI GỢI Ý

"DataFrame huấn luyện gồm vector features 27 chiều, binary_label và class_weight chỉ được tính từ Train. Spark phân phối các partition để tính thống kê chia nhánh cho Random Forest. Mô hình gồm 20 cây, độ sâu tối đa 5, maxBins 32 và seed 42. Vì là mô hình cây, nhóm không chuẩn hóa thang đo feature. Validation được dùng để so sánh baseline với weighted; sau khi chọn weighted, mô hình được đóng băng rồi Test đúng một lần và lưu tại models/random_forest_full_weighted."

ĐIỂM CẦN NHẤN

• class_weight là tham số huấn luyện, không phải feature và không xuất hiện trong Kafka.
• Random Forest xử lý phi tuyến và không cần standard scaling như mô hình khoảng cách.
• Test không được dùng để điều chỉnh quyết định sau khi xem kết quả.

CÂU CHUYỂN

"Sau khi có model đóng băng, dữ liệu lịch sử được chuyển thành dòng sự kiện để kiểm thử realtime."

NẾU THẦY HỎI

Nếu hỏi vì sao chỉ 20 cây/depth 5: đây là cấu hình baseline có kiểm soát, cân bằng tài nguyên và khả năng kiểm chứng; đề tài chưa thực hiện tuning mở rộng.

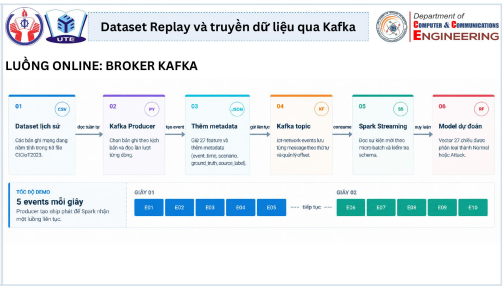
CHƯƠNG 3 · KIẾN TRÚC VÀ XỬ LÝ BIG DATA

Kafka replay: biến bản ghi lịch sử thành dòng sự kiện

SLIDE 21 · THỜI LƯỢNG GỢI Ý: 55–70 giây

MỤC TIÊU CỦA SLIDE

Giải thích replay là mô phỏng streaming có nhịp thời gian, không phải thu gói mạng trực tiếp.



LỜI NÓI GỢI Ý

"Do nguồn của đề tài là dataset lịch sử, producer đọc từng dòng theo kịch bản và phát đều, ví dụ 5 sự kiện mỗi giây. Mỗi sự kiện giữ 27 feature, đồng thời thêm event_time, scenario, ground_truth và source_label để theo dõi và đánh giá. Kafka lưu sự kiện theo topic, partition và offset, giúp producer và Spark chạy độc lập về tốc độ. Đây là cơ chế replay để mô phỏng dòng liên tục, không phải packet capture trực tiếp từ thiết bị thật."

ĐIỂM CẦN NHẤN

- Kafka tạo tính liên tục, đệm và định danh sự kiện; không làm sạch hay dự đoán.
- scenario/ground_truth là metadata demo; model chỉ nhìn 27 feature.
- Có thể đổi kịch bản mà không khởi động lại Spark hay dashboard.

CÂU CHUYỂN

"Từ Kafka, Spark Structured Streaming tiếp nhận từng micro-batch và kiểm tra sự kiện trước khi suy luận."

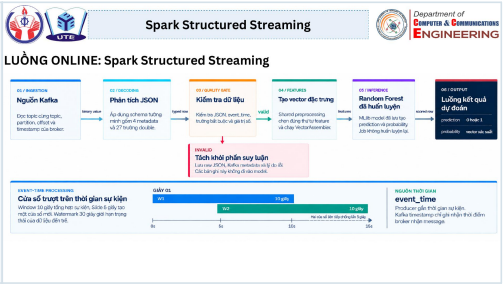
CHƯƠNG 3 · KIẾN TRÚC VÀ XỬ LÝ BIG DATA

Structured Streaming: kiểm tra và suy luận

SLIDE 22 · THỜI LƯỢNG GỢI Ý: 75–90 giây

MỤC TIÊU CỦA SLIDE

Trình bày quality gate, hai nhánh valid/invalid và cơ chế event-time window.



LỜI NÓI GỢI Ý

“Spark đọc Kafka source rồi parse JSON theo schema tường minh gồm bốn metadata và 27 số thực. Quality gate kiểm tra timestamp, trường bắt buộc và giá trị số. Event hợp lệ được tạo vector 27 chiều và đưa qua Random Forest để sinh prediction cùng probability. Event không hợp lệ không vào model mà được giữ raw JSON, metadata Kafka và lý do lỗi để kiểm tra. Analytics dùng cửa sổ event time 10 giây, trượt 5 giây và watermark 30 giây để xử lý dữ liệu đến trễ.”

ĐIỂM CẦN NHẤN

• Event time lấy từ producer; Kafka timestamp chỉ là thời điểm broker nhận.
• Watermark không phải thời lượng cửa sổ; nó là ngưỡng chấp nhận dữ liệu trễ.
• Prediction do model tạo; scenario và ground_truth chỉ dùng đối chiếu.

CÂU CHUYỂN

“Sau suy luận, cùng một prediction stream được dùng để tạo chỉ số, trạng thái và cảnh báo.”

NẾU THẦY HỎI

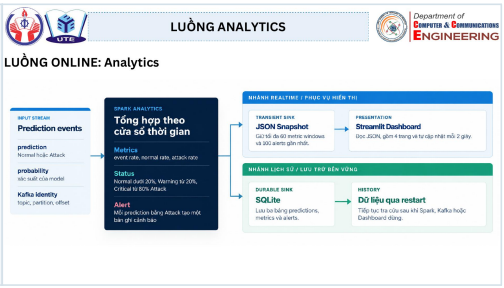
Nếu hỏi vì sao dùng window 10 giây/slide 5 giây: cửa sổ chồng lấn cho cập nhật thường xuyên mà vẫn đủ mẫu để tính tỷ lệ; đây là cấu hình demo có thể điều chỉnh.

Analytics, cảnh báo, dashboard và lưu trữ

SLIDE 23 · THỜI LƯỢNG GỢI Ý: 80–95 giây

MỤC TIÊU CỦA SLIDE

Làm rõ thứ tự sau inference và sự khác nhau giữa nhánh realtime với nhánh lịch sử.



LỜI NÓI GỢI Ý

"Mỗi prediction event gồm prediction, probability và định danh Kafka topic–partition–offset. Spark tổng hợp theo cửa sổ để tính event rate, normal rate và attack rate. Trạng thái được gán Normal dưới 20%, Warning từ 20% và Critical từ 80% Attack. Mỗi dự đoán Attack sinh một bản ghi cảnh báo, tức là một dòng dữ liệu alert chứ không phải file CSV. Sau đó luồng tách thành hai nhánh: snapshot JSON giữ trạng thái gần nhất cho Streamlit; SQLite lưu bền ba bảng predictions, metrics và alerts để tra cứu sau khi hệ thống khởi động lại."

ĐIỂM CẦN NHẤN

• Thứ tự: prediction aggregate metrics/status alert hai sink.
• Dashboard đọc JSON và tự cập nhật 2 giây; không đọc trực tiếp SQLite trong MVP.
• SQLite là durable sink; JSON là transient snapshot.

CÂU CHUYỂN

"Nhìn toàn bộ pipeline, đề tài thể hiện đủ năm đặc trưng 5V của một bài toán Big Data."

NẾU THẦY HỎI

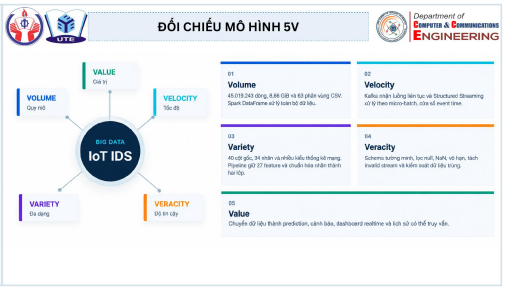
Nếu hỏi chống ghi trùng khi restart: predictions/alerts định danh bằng topic–partition–offset; metric dùng khóa cửa sổ để insert/upsert một cách idempotent.

Đối chiếu hệ thống theo mô hình 5V

SLIDE 24 · THỜI LƯỢNG GỢI Ý: 65–80 giây

MỤC TIÊU CỦA SLIDE

Chứng minh đề tài Big Data bằng bằng chứng cụ thể, không định nghĩa 5V chung chung.



LỜI NÓI GỢI Ý

"Volume thể hiện ở 45.019.243 dòng, khoảng 8,66 GiB và 63 tệp được Spark xử lý phân tán. Velocity đến từ dòng Kafka liên tục và micro-batch theo event time. Variety nằm ở 40 cột gốc, 34 nhãn và nhiều nhóm đặc trưng. Veracity được kiểm soát qua schema, lọc null/NaN/vô cực, nhánh invalid và loại trùng. Value là khả năng chuyển dữ liệu thành dự đoán, cảnh báo, dashboard realtime và lịch sử có thể truy vấn."

ĐIỂM CẦN NHẤN

- Mỗi V gắn với một số đo hoặc cơ chế trong chính hệ thống.
- Variety không chỉ là nhiều định dạng file; còn là nhiều loại tín hiệu và nhãn.
- Value là đầu ra sử dụng được, không phải điểm mô hình đơn lẻ.

CÂU CHUYỂN

"Sau kiến trúc, nhóm chuyển sang bằng chứng thực nghiệm trên toàn bộ dữ liệu đã xử lý."

LƯU Ý / KHÔNG NÊN NÓI

Không nhầm slide này với năm khía cạnh chất lượng ở slide 16. Hai bộ khái niệm có mục tiêu khác nhau.

CHƯƠNG 4 · KẾT QUẢ THỰC NGHIỆM

Quy mô dữ liệu và thiết kế thí nghiệm

SLIDE 25–26 · THỜI LƯỢNG GỢI Ý: 65–80 giây

MỤC TIÊU CỦA SLIDE

Nhắc lại số liệu đầu vào và giải thích vì sao đánh giá không bị leakage.



LỜI NÓI GỢI Ý

"Thực nghiệm bắt đầu với 45.019.243 dòng. Sau lọc lỗi còn 45.018.243 và sau dedup còn 20.362.785 mẫu học duy nhất. Dữ liệu được chia cố định 70% Train, 15% Validation và 15% Test bằng seed 42. Sau dedup, Attack vẫn có 19.208.349 mẫu còn Normal chỉ 1.154.436, tương đương chênh lệch khoảng 16,6 lần. Đây là lý do nhóm thử class weighting và không dựa vào Accuracy đơn thuần."

ĐIỂM CẦN NHẤN

- Dedup trước split và seed cố định giúp thí nghiệm có thể tái lập.
- Validation chọn phương án; Test báo cáo cuối cùng.
- Mất cân bằng vẫn còn sau dedup, nên weighted model là một thử nghiệm có cơ sở.

CÂU CHUYỂN

"Kết quả cho thấy weighted model tạo ra một trade-off rất rõ giữa phát hiện Attack và giảm cảnh báo nhầm Normal."

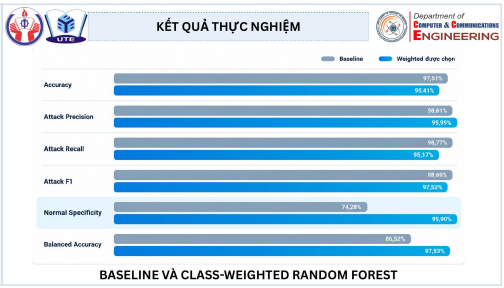
CHƯƠNG 4 · KẾT QUẢ THỰC NGHIỆM

Baseline và weighted: đọc đúng trade-off

SLIDE 27 · THỜI LƯỢNG GỢI Ý: 85–100 giây

MỤC TIÊU CỦA SLIDE

Giải thích vì sao mô hình được chọn dù Accuracy và Attack Recall thấp hơn baseline.



LỜI NÓI GỢI Ý

"Baseline có Accuracy 97,51% và Attack Recall 98,77%, nhưng Normal Specificity chỉ 74,28%, nghĩa là báo động nhầm nhiều mẫu Normal. Weighted model giảm Accuracy còn 95,41% và Attack Recall còn 95,17%, nhưng Normal Specificity tăng lên 99,90% và Balanced Accuracy tăng từ 86,52% lên 97,53%. Nhóm chọn weighted cho MVP vì cần một kịch bản NORMAL ổn định và giảm false positive trong vận hành, đồng thời chấp nhận bỏ sót Attack nhiều hơn."

ĐIỂM CẦN NHẤN

- Không nói weighted tốt hơn trên mọi mặt; nó tốt hơn theo mục tiêu vận hành đã chọn.
- Balanced Accuracy cân bằng Recall của Attack và Specificity của Normal.
- Quyết định chọn weighted được đưa ra trên Validation trước khi xem Test.

CÂU CHUYỂN

"Ma trận nhầm lẫn cho thấy cụ thể số false positive giảm và số false negative tăng như thế nào."

LƯU Ý / KHÔNG NÊN NÓI

Trong IDS ưu tiên không bỏ sót Attack, baseline có thể phù hợp hơn. Hãy trình bày weighted là lựa chọn trade-off của MVP, không phải đáp án tối ưu cho mọi triển khai.

CHƯƠNG 4 · KẾT QUẢ THỰC NGHIỆM

Ma trận nhầm lẫn – phải sửa trước khi trình chiếu

SLIDE 28 · THỜI LƯỢNG GỢI Ý: 90–110 giây

MỤC TIÊU CỦA SLIDE

Ngăn trình bày sai: slide nguồn đang gắn nhãn và một số giá trị không đúng với kết quả đã xác minh.



So sánh ma trận nhầm lẫn

LỜI NÓI GỢI Ý

"Quy ước Attack là lớp dương. Với baseline: TN 116.694, FP 40.404, FN 35.741, TP 2.863.322. Với weighted: TN 156.935, FP 163, FN 140.030, TP 2.759.033. Như vậy weighted giảm false positive từ 40.404 xuống 163, nhưng false negative tăng từ 35.741 lên 140.030. Đây chính là cái giá phải trả để hệ thống ít báo động nhầm hơn."

ĐIỂM CẦN NHẤN

- Hàng thực tế Normal: TN, FP. Hàng thực tế Attack: FN, TP.
- FP = Normal bị báo nhầm Attack; FN = Attack bị bỏ sót.
- So sánh hai lỗi quan trọng hơn chỉ nhìn hai ô dự đoán đúng.

CÂU CHUYỂN

"Sau khi hiểu hiệu năng, nhóm xem những feature nào đóng góp nhiều nhất vào các quyết định của Random Forest."

LƯU Ý / KHÔNG NÊN NÓI

Slide 28 trong Big Data.pdf hiện đang sai. Các ô bị diễn giải lẫn TP/TN và FN/FP; weighted còn hiển thị 183 và 2.758.033 thay vì 163 và 2.759.033. Hãy sửa slide theo các số đúng ở phần lời nói gợi ý. Số liệu đã đối chiếu với TASKS.md và data/README.md của dự án.

NẾU THẦY HỎI

Nếu hỏi 'thà báo nhầm còn hơn bỏ sót Attack?': đúng trong môi trường an ninh ưu tiên an toàn tuyệt đối; khi đó baseline là lựa chọn hợp lý hơn. MVP chọn weighted để minh họa vận hành ít nhiễu, và nhóm công khai hạn chế FN tăng.

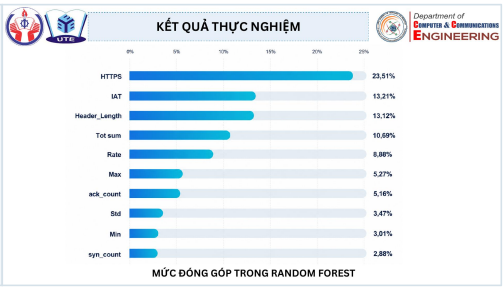
CHƯƠNG 4 · KẾT QUẢ THỰC NGHIỆM

Top 10 feature importance

SLIDE 29 · THỜI LƯỢNG GỢI Ý: 60–75 giây

MỤC TIÊU CỦA SLIDE

Giải thích mô hình kết hợp nhiều nhóm tín hiệu; không diễn giải importance như quan hệ nhân quả.



LỜI NÓI GỢI Ý

"Theo feature importance của Random Forest, HTTPS đóng góp lớn nhất với 23,51%, tiếp theo là IAT 13,21% và Header_Length 13,12%. Nhóm top 10 còn có tổng kích thước, Rate, Max, ack_count, Std, Min và syn_count; tổng cộng chiếm 89,20% importance. Điều này cho thấy mô hình không dựa vào một tín hiệu đơn lẻ mà kết hợp thông tin ứng dụng, thời gian, kích thước gói và TCP."

ĐIỂM CẦN NHẤN

- Đây chỉ là top 10 trong 27 feature.
- Importance là mức đóng góp tương đối trong mô hình đã huấn luyện, không chứng minh nguyên nhân tấn công.
- Không dùng riêng biểu đồ này để kết luận loại 17 feature còn lại.

CÂU CHUYỂN

"Cuối cùng, nhóm kiểm tra toàn bộ pipeline bằng chuỗi kịch bản liên tục từ Normal sang Attack rồi phục hồi."

NẾU THẦY HỎI

Nếu hỏi importance tính như thế nào: đây là importance dựa trên mức giảm độ hỗn tạp qua các điểm chia của các cây trong Random Forest, được chuẩn hóa để tổng bằng 1.

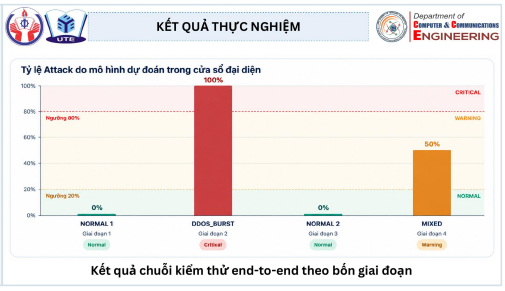
CHƯƠNG 4 · KẾT QUẢ THỰC NGHIỆM

Kiểm thử end-to-end qua bốn giai đoạn

SLIDE 30 · THỜI LƯỢNG GỢI Ý: 70–85 giây

MỤC TIÊU CỦA SLIDE

Chứng minh hệ thống phản ứng đúng theo thời gian và không cần reload giữa các kịch bản.



Kết quả chuỗi kiểm thử end-to-end theo bốn giai đoạn

LỜI NÓI GỢI Ý

"Nhóm chạy một chuỗi liên tục trên cùng Spark process và cùng dashboard. Giai đoạn NORMAL 1 cho 0% Attack nên trạng thái Normal. Khi chuyển sang DDoS burst, tỷ lệ lên 100% và hệ thống chuyển Critical. Sau đó NORMAL 2 đưa tỷ lệ về 0%, chứng minh hệ thống phục hồi theo cửa sổ mới. Cuối cùng MIXED đạt 50% nên trạng thái Warning. Kết quả cho thấy dữ liệu đi xuyên suốt từ producer, Kafka, Spark, model đến analytics và dashboard mà không cần tải lại trang."

ĐIỂM CẦN NHẤN

- Đây là tỷ lệ Attack do model dự đoán trong cửa sổ đại diện.
- Ngưỡng: Normal <20%, Warning từ 20% đến dưới 80%, Critical từ 80%.
- Giá trị của thử nghiệm là chuyển trạng thái liên tục, không chỉ chạy bốn lệnh rời rạc.

CÂU CHUYỂN

"Như vậy, bốn chương đầu đã chứng minh từ dữ liệu lớn, mô hình đến khả năng vận hành realtime của hệ thống."

LƯU Ý / KHÔNG NÊN NÓI

Không nói 0%/100%/50% là độ chính xác tổng quát của mô hình; đây là kết quả của các cửa sổ demo đại diện.

ÔN NHANH TRƯỚC KHI THUYẾT TRÌNH

Mười câu hỏi dễ bị hội đồng hỏi

THỜI LƯỢNG GỢI Ý: Đọc lại 5 phút trước khi vào phòng

1 · Vì sao đây là Big Data?

Vì có 45 triệu dòng/8,66 GiB, xử lý phân tán bằng Spark, dòng Kafka liên tục, event-time window, dữ liệu đa dạng và đầu ra vận hành được.

2 · 40 cột hay 27 feature?

40 cột ban đầu = 39 feature + Label. Sau EDA giữ 27 feature; Label được giữ riêng để tạo binary_label và đánh giá.

3 · Vì sao loại trùng trước khi chia?

Để cùng một mẫu học không xuất hiện ở Train và Test, tránh leakage và điểm số lạc quan giả.

4 · Kafka có dự đoán không?

Không. Kafka đệm, truyền và định danh sự kiện; Spark + model mới thực hiện suy luận.

5 · Replay có phải dữ liệu IoT live thật không?

Không. Đây là dataset lịch sử được phát theo nhịp để mô phỏng dòng sự kiện realtime và kiểm thử kiến trúc.

6 · Tại sao dashboard không đọc SQLite?

MVP dùng JSON snapshot để hiển thị trạng thái live nhanh; SQLite là kho lịch sử bền vững. Hai sink phục vụ hai mục tiêu khác nhau.

7 · Tại sao chọn weighted khi Attack Recall giảm?

Để giảm false positive mạnh và có vận hành Normal ít nhiễu; đây là trade-off của MVP, không phải lựa chọn tối ưu cho mọi IDS.

8 · Chỉ số nào quan trọng?

Attack Recall/F1 cho khả năng bắt tấn công; Normal Specificity/FPR cho cảnh báo nhầm; Balanced Accuracy để nhìn cân bằng hai lớp.

9 · Model có tự cập nhật online không?

Không. Model được huấn luyện offline, đóng băng và nạp cho streaming. Tái huấn luyện là hướng phát triển riêng.

10 · Hạn chế quan trọng nhất?

Replay chưa phải traffic thật; binary classification không chỉ loại tấn công; SQLite phù hợp MVP hơn là hệ lưu trữ phân tán quy mô lớn; trade-off FN/FP vẫn cần tối ưu theo nghiệp vụ.

CHECKLIST

Những việc cần sửa/kiểm tra trước buổi bảo vệ

THỜI LƯỢNG GỢI Ý: 10 phút

BẮT BUỘC SỬA

- Sửa slide 28 về đúng quy ước và số liệu: Baseline TN 116.694, FP 40.404, FN 35.741, TP 2.863.322; Weighted TN 156.935, FP 163, FN 140.030, TP 2.759.033.
- Đảm bảo slide 23 dùng cụm "tổng hợp theo cửa sổ thời gian", không phải "cửa số".

KIỂM TRA KHI DEMO

- Kafka và Spark đã chạy; dashboard mở đúng địa chỉ; dữ liệu NORMAL đã chảy ổn định trước khi đổi kịch bản.
- Khi chuyển DDoS/MIXED, chờ đủ cửa sổ 10 giây và nhịp refresh 2 giây trước khi kết luận.
- Nếu metric chưa đổi ngay, giải thích do cửa sổ trượt/event time, không bấm reload liên tục.

CÁCH KẾT THÚC CHƯƠNG 4

"Kết quả cho thấy hệ thống đã xử lý được dữ liệu quy mô lớn, huấn luyện mô hình bằng MLlib và đưa model vào một pipeline streaming hoàn chỉnh. Nhóm cũng công khai trade-off giữa false positive và false negative thay vì chỉ báo cáo Accuracy."

PHẠM VI TÀI LIỆU

Tài liệu dừng ở cuối Chương 4 theo yêu cầu. Chương 5 (Kết luận/hướng phát triển) và Chương 6 (Demo) không được viết thành kịch bản riêng.